

**LAPORAN AKHIR
PENELITIAN MAHASISWA**



**Deteksi Beban Mental Berdasarkan Sinyal Electroencephalogram Menggunakan Kecerdasan
Artifisial**

TIM PENGUSUL :

Nuhaa Salsabila Shidqiyyah	22031554045
Reinesa Eveniashari Purwasarani	22031554026
Varel Dany Ekamartha	22031554001
Selvy Aulia Ramadhan	22031554004

UNIVERSITAS NEGERI SURABAYA

2023

HALAMAN PENGESAHAN

HALAMAN PENGESAHAN LAPORAN AKHIR PENELITIAN MAHASISWA

- | | |
|-------------------------------|--|
| 1. Judul Penelitian | : Deteksi Beban Mental Manusia Berdasarkan Electroencephalogram Menggunakan Kecerdasan Artfisial |
| 2. Bidang Ilmu | : Bidang Ilmu Komputer |
| 3. Tim Peneliti | : |
| Ketua Peneliti | |
| a. Nama Lengkap | : Nuhaa Salsabila Shidqiyyah |
| b. NIM | : 22031554045 |
| c. Fakultas/Jurusan | : FMIPA/Sains Data |
| d. AlamatInstitusi | : Jl. Ketintang, Ketintang, Kec. Gayungan, Surabaya, Jawa Timur 60231 |
| e. Telpon/Faks/e-mail | : 0318280009 |
| Anggota (1) | |
| a. Nama | : Varel Dhani Ekamartha |
| b. NIM | : 22031554001 |
| c. Fakultas | : FMIPA/Sains Data |
| Anggota (2) | |
| a. Nama | : Selvy Aulia Ramadhan |
| b. NIM | : 22031554004 |
| c. Fakultas | : FMIPA/Sains Data |
| Anggota (3) | |
| a. Nama | : Reinesa Eveniashari Purwasarani |
| b. NIM | : 22031554021 |
| c. Fakultas | : FMIPA/Sains Data |
| 4. Waktu Penelitian | : Mei – November 2023 |
| 5. Jumlah dana yang disetujui | : Rp. 2.750.000 |

Surabaya, 4 Juli 2023


Menyetujui,
Dosen Pembimbing Penelitian,


Dr. Elly Marliah, M.Kom.
NIP 198204052005012002

Mengetahui
Dekan Fakultas,

Prof. Dr. Wasia, M.Si.
NIP 198705202014042001

Ketua Peneliti


Nuhaa Salsabila Shidqiyyah
NIM 22031554045

Menyetujui,
Direktur LPPM Unesa

Prof. H. Muhammad Turhan Yani, M.ANIP
197703012002121003

DAFTAR ISI

HALAMAN PENGESAHAN	2
DAFTAR ISI	3
RINGKASAN.....	4
PRAKATA	5
BAB I PENDAHULUAN	6
1.1 Latar Belakang.....	6
BAB II KAJIAN TEORI	9
2.1 Mental Workload dan Electroencephalogram	9
2.2 Random Forest.....	9
2.3 WEKA	10
BAB III TUJUAN DAN MANFAAT	11
3.3 Tujuan	11
3.4 Manfaat	11
BAB IV METODE PENELITIAN	12
4.1 Pra-Pemrosesan Data	12
4.2 Ekstraksi Fitur.....	13
4.3 Proses Klasifikasi.....	14
BAB V.....	15
HASIL DAN LUARAN YANG DICAPAI	15
5.1 Data Set.....	15
5.2 Akurasi Hasil Klasifikasi	16
5.3 Pembahasan	18
BAB VII.	19
KESIMPULAN DAN SARAN	19
BAB VIII DAFTAR PUSTAKA.....	20
LOGBOOK.....	22

RINGKASAN

Mental workload atau beban kerja mental dipengaruhi oleh faktor-faktor seperti tuntutan tugas, stres, dan kelelahan kondisi psikologis dan fisik manusia dapat memengaruhi proses berpikir. Apabila kondisi individu mengalami kelelahan, maka dapat memengaruhi penurunan tingkat produktifitas maupun penurunan proses berpikir. Kelelahan yang dialami tersebut menjadi suatu penyebab adanya beban kerja mental atau mental workload. Mental workload dijelaskan sebagai kebutuhan tugas dalam hal kesulitan, kompleksitas, dan tekanan temporal atau upaya yang dilakukan untuk memenuhi persyaratan pekerjaan. Semakin besar mental workload pada individu, semakin tinggi pula kemungkinan risiko kelelahan yang dapat berpengaruh pada penurunan produktivitas kerja. Electroencephalogram (EEG) adalah teknik *neuroimaging* berbiaya rendah yang mengukur dan merekam potensi listrik yang dihasilkan dari aktivitas otak dan digunakan untuk menguji proses kognitif. Perangkat EEG bekerja dengan menangkap aktivitas listrik pada permukaan kulit kepala. Melalui sinyal EEG kondisi pikiran seseorang dapat diketahui sekalipun orang tersebut tidak melakukan suatu gerakan fisik apapun. Urgensi penelitian ini adalah mengidentifikasi ukuran tingkat beban mental setiap individu dengan menggunakan analisis sinyal EEG dan mengetahui identifikasi sinyal otak terhadap kelelahan mental yang berlebihan. Tujuan penelitian ini mendapatkan fitur terbaik dari sinyal EEG, Mengklasifikasikan tingkat beban mental menggunakan algoritma *Random Forest*, mengetahui performa attribute dan algoritma *Random Forest*. Penelitian ini akan melakukan deteksi beban mental seseorang berdasarkan sinyal EEG menggunakan *Random Forest*. Dengan dilakukan deteksi mentalworkload berdasarkan aktivitas otak manusia terkait isu mental workload memberikan kontribusi penting dalam pemahaman tentang dampak beban kerja yang berlebihan pada kesehatan mental dan kognisi manusia. Melalui penelitian ini, diharapkan dapat dikembangkan strategi dan intervensi yang efektif untuk mengurangi risiko mental workload. Luaran penelitian ini berupa program computer yang telah didaftarkan HKI-nya serta publikasi jurnal terindeks nasional.

Kata kunci : *Mental Workload*, Electroencephalogram, Random Forest, Neurocognition, Kecerdasan Artifisial

PRAKATA

Puji syukur panjatkan kepada Tuhan Yang Maha Esa. Atas semua kehendaknya, sehingga penyusunan laporan kemajuan berjalan lancar. Dalam era modern yang penuh tantangan ini, pemahaman terhadap kesejahteraan mental menjadi semakin penting. Dengan kemajuan teknologi dan ilmu pengetahuan, kita memiliki kesempatan untuk menggabungkan pengetahuan dalam neurologi dengan kecerdasan buatan untuk menciptakan solusi yang inovatif dalam pemantauan deteksi beban mental.

Ucapan terima kasih kepada pembimbing kami ibu Dr. Elly Matul Immah, M. Kom. serta semua pihak yang telah mendukung proyek ini, serta kepada individu dan kelompok yang telah berpartisipasi dalam studi ini. Penulis menyadari bahwa hasil penelitian yang dibuat masih jauh dari kata sempurna, dan memiliki kekurangan dari berbagai aspek. Untuk itu, penulis menerima kritik dan saran yang bersifat membangun demi perbaikan laporan penelitian ini.

Surabaya, 3 Oktober 2023

Penulis

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kesehatan mental adalah aspek penting dalam mewujudkan kesehatan yang menyeluruh. Namun di sebagian besar negara berkembang, masalah kesehatan mental belum diprioritaskan apabila dibandingkan dengan penyakit menular[1]. Sebagai salah satu sektor yang paling berpengaruh terhadap pandemi, kesehatan mental merupakan salah satu bidang kesehatan masyarakat yang paling terabaikan. Sumber daya manusia merupakan aset utama perusahaan baik sektor formal maupun sektor informal yang perlu diperhatikan, dengan tetap memperhatikan berbagai sumber daya yang lain seperti modal, mesin, waktu, energi, dan informasi[2]. Dalam beroperasi melakukan kegiatan, setiap organisasi membutuhkan tenaga kerja yang berperan dalam meningkatkan produk secara berkualitas.

Masa depan Indonesia terletak pada Sumber Daya Alam, namun seiring banyaknya manusia, investasi pada Sumber Daya Manusia yang berkualitas akan membuat Indonesia maju. Untuk mewujudkan pembangunan berkelanjutan pada tahun 2030 dan tercapainya Indonesia maju tahun 2045 tujuan terwujudnya jaminan kehidupan yang sehat dan mendorong kesejahteraan bagi semua orang di segala usia dengan salah satu target mengurangi angka kematian dini yang diakibatkan oleh penyakit tidak menular melalui pencegahan dan pengobatan, serta meningkatkan kesehatan mental dan kesejahteraan. Stres kerja dapat berdampak buruk pada kondisi kejiwaan apabila tidak dilakukan penanggungan dalam menjalankan aktivitasnya, banyak individu mengalami tekanan untuk melakukan tugas yang kompleks, mengatasi deadline yang ketat, serta menjaga kinerja optimal secara konsisten sehingga hal tersebut dalam menyebabkan peningkatan beban kerja mental. Tingginya tekanan beban mental dapat menyebabkan stress kronis, kelelahan mental, penurunan produktivitas, bahkan gangguan kesehatan mental seperti kecemasan dan depresi.

Beban kerja mental atau *mental workload* dapat mempengaruhi kinerja manusia dan dianggap penting dalam desain serta evaluasi untuk sistem manusia mesin yang kompleks[3]. Setiap individu memiliki tingkat kapasitas mental workload berbeda. Salah satu cara untuk mengukur tingkat mental

workload seorang individu bisa menggunakan electroencephalogram (EEG)[4]. Electroencephalogram (EEG) adalah sinyal yang dihasilkan dari perangkat yang digunakan untuk mengukur potensi listrik dari otak. Zhou dan timnya melakukan penelitian berupa telaah artikel tentang EEG dan mental workload. Pada penelitiannya Zhou dan tim menyatakan bahwa akhir-akhir ini pengenalan mental workload banyak dilakukan menggunakan kecerdasan artifisial khususnya machine learning berdasarkan data sinyal EEG[5]. Penelitian Guan beserta tim yang membahas kontrol kognitif juga menggunakan EEG dan mengaitkan dengan kondisi mental workload seseorang[6]. L Longo dan tim melakukan penelitian yang menghasilkan model load kognitif sebagai selfsupervised-brain rate dengan EEG menggunakan deep learning[7].

Penelitian lainnya tentang cognitive workload dilakukan oleh Anmol Gupta dan tim menggunakan algoritma LSTM dan CNN[8]. Dalam penelitian ini kami melakukan deteksi kondisi mental workload berdasarkan EEG menggunakan algoritma Random Forest. Ekstraksi fitur merupakan salah satu tahap penting dalam machine learning. Fitur yang tepat akan mempengaruhi performa sistem dalam melakukan deteksi. Penelitian yang dilakukan oleh Dessy dan tim yang menggunakan metode Principal Component Analysis (PCA) untuk mendapatkan ciri dalam ekstraksi fitur[4]. Zian Pei menggunakan seleksi fitur dalam menentukan fitur terbaik untuk meningkatkan performa identifikasi mental workload [9]. Dalam penelitian ini kami menggunakan beberapa fitur sebagai pembanding untuk ekstraksi fitur. Z Markov dan tim dalam penelitiannya menyatakan bahwa Waikato Environment for Knowledge Analysis (WEKA) menyediakan seperangkat algoritma machine learning yang kuat untuk data mining[10]. Diharapkan penelitian ini dapat memberikan manfaat baik secara langsung maupun tidak langsung. Adapun manfaat dari penelitian ini diantaranya Sinyal EEG dapat digunakan sebagai alat objektif untuk mengukur tingkat beban kerja mental yang dialami oleh individu. Dengan analisis sinyal EEG, peneliti dapat mengidentifikasi biomarker yang terkait dengan tingkat beban kerja mental, seperti perubahan dalam pola aktivitas otak atau frekuensi gelombang tertentu. Hal ini memberikan pendekatan yang lebih tepat dan dapat diandalkan dalam mengukur dan memahami tingkat beban kerja mental individu.

Urgensi penelitian ini adalah mengidentifikasi ukuran tingkat beban mental setiap individu dengan menggunakan analisis sinyal EEG dan mengetahui identifikasi sinyal otak terhadap kelelahan mental yang berlebihan, lain keutamaan yaitu deteksi sinyal EEG berdasarkan aktivitas otak manusia terkait isu mental workload dengan memberikan kontribusi penting dalam pemahaman tentang dampak beban kerja yang berlebihan pada kesehatan mental dan kognisi manusia. Melalui penelitian ini, diharapkan dapat dikembangkan strategi dan intervensi yang efektif untuk mengurangi risiko mental workload.

Dalam penelitian mendatang, fokus akan diperluas untuk memperbaiki ketepatan dan keakuratan deteksi beban mental menggunakan sinyal *electroencephalogram* (EEG) dengan memanfaatkan kecerdasan buatan. Penelitian akan terus mengembangkan algoritma yang lebih canggih

dan akurat untuk menganalisis sinyal otak terkait beban mental dari data EEG. Selain itu, perhatian khusus akan diberikan pada pengembangan metode deteksi sinyal otak yang dapat mengidentifikasi dan membedakan pola-pola khusus yang terkait dengan penderita penyakit kecemasan (anxiety). Integrasi data EEG pada penderita kecemasan akan memberikan wawasan lebih mendalam tentang korelasi antara aktivitas otak dan gejala-gejala kecemasan. Hasil penelitian ini diharapkan dapat memberikan dasar untuk pengembangan yang lebih terarah dan personal untuk individu dengan beban mental dan gangguan kecemasan.

BAB II

KAJIAN TEORI

2.1 Mental Workload dan Electroencephalogram

Mental Workload dan Electroencephalogram (EEG) adalah perangkat khusus yang digunakan untuk mengukur potensi listrik dari otak[11]. Perangkat EEG bekerja dengan menangkap aktivitas listrik pada permukaan kulit kepala. Sinyal hasil perekaman dari perangkat EEG disebut sebagai sinyal EEG. Melalui sinyal EEG kondisi pikiran seseorang dapat diketahui sekalipun orang tersebut tidak melakukan suatu gerakan fisik apapun. Banyak variabel yang dapat ditinjau untuk menentukan kondisi pikiran seseorang berdasarkan sinyal EEG[12]. Dataset yang digunakan dalam penelitian ini adalah STEW: Simultaneous Task EEG Dataset dengan 45 subjek. Kumpulan data ini terdiri dari data EEG mentah dari 48 subjek yang berpartisipasi dalam eksperimen beban kerja multitasking dengan menggunakan multitasking modul tes simultaneous capacity atau SIMKAP. SIMKAP dari Vienna Test System, merupakan tes psikologis yang digunakan untuk mengevaluasi multitasking dan toleransi stress individu[13]. Diterapkan pada peserta sebagai perangkat eksperimen. Uji coba antarmuka yang diterapkan menggunakan set percobaan diberikan pada Gambar 1. Eksperimen terdiri dari dua sesi, keadaan istirahat sebelum tes dilakukan, dan pada saat melakukan test atau saat . Pada sesi pertama tidak ada tugas yang diberikan kepada peserta dan peserta diminta istirahat. Aktivitas otak subjek saat istirahat juga direkam sebelum tes dan juga disertakan. Perangkat Emotiv EPOC, dengan frekuensi pengambilan sampel 128 Hz dan 14 saluran digunakan untuk mendapatkan data, dengan 2,5 menit perekaman EEG untuk setiap kasus. Subjek juga diminta untuk menilai beban kerja mental yang mereka rasakan setelah setiap tahap dengan skala penilaian 1 hingga 9 dan penilaian disediakan dalam file terpisah[4].

2.2 Random Forest

Algoritma yang paling cepat untuk membangun model adalah algoritma Random Forest. Algoritma Random Forest dipilih karena mampu mengklasifikasikan banyak data[4]. Dimana Random Forest terdiri dari banyak pohon keputusan serta memiliki kesalahan klasifikasi yang rendah

dibandingkan dengan algoritma tradisional lainnya[14]. Seperti metode berbasis pohon lainnya, Random Forest dapat menangani kumpulan data dalam jumlah besar dengan banyak prediktor menggunakan pemilihan faktor otomatis dan tanpa penghapusan faktor. Matthias Schonlau dan timnya melakukan penelitian berupa pembelajaran statistik yang menggunakan algoritma Random Forest. Dalam penelitian Matthias Schonlau menyatakan bahwa algoritma Random Forest merupakan mesin untuk prediksi dengan banyak data dengan mudah[15]. Random Forest meningkatkan keragaman antara pohon klasifikasi dengan melakukan sampling ulang data dengan penggantian dan secara acak mengubah himpunan variabel prediksi atas berbagai cara induksi pohon.

Random Forest memerlukan waktu dalam pembuatan model, berbeda dengan KNN yang tidak memerlukan waktu sama sekali. Namun waktu pembuatan model Random Forest relatif lebih singkat karena algoritma ini bekerja menggunakan konsep tree, sehingga proses pencocokan lebih efisien meskipun dataset dalam jumlah besar, selama tidak terlalu banyak kelas[4]. Alasan ini sesuai dengan[16], algoritma Random Forest yang akurat karena setiap pohon keputusan dapat membuat keputusan klasifikasi hanya berdasarkan fitur yang efektif

2.3 WEKA

WEKA (Waikato Environment for Knowledge Analysis) Waikato Environment for Knowledge Analysis(WEKA) merupakan perangkat lunak pembelajaran mesin populer yang ditulis dalam bahasa pemrograman java, dikembangkan oleh Universitas Waikato di Selandia Baru[17]. WEKA berisikan kumpulan algoritma beserta visualisasinya untuk analisis data dan permodelan prediktif. Algoritma pembelajaran mesin pada WEKA dapat menerapkan semua teknik pembelajaran untuk klasifikasi dan regresi, yaitu pohon keputusan, Support Vector Machines (SVM), logistik dan linier, multi layers perceptrons dan metode nearest neighbour[17].

BAB III

TUJUAN DAN MANFAAT

3.3 Tujuan

1. Mendapatkan fitur terbaik dari sinyal EEG untuk bisa digunakan data klasifikasi beban mental
2. Mengklasifikasikan tingkat beban mental (workload) pada tiap individu berdasarkan data EEG menggunakan kecerdasan artifisial algoritma Random Forest

Mengetahui dan mengevaluasi performa Attribute dan algoritma Random Forest dalam mengklasifikasi sinyal EEG Manfaat Berdasarkan tujuan penelitian yang hendak dicapai, maka diharapkan penelitian ini dapat memberikan manfaat baik secara langsung maupun tidak langsung.

3.4 Manfaat

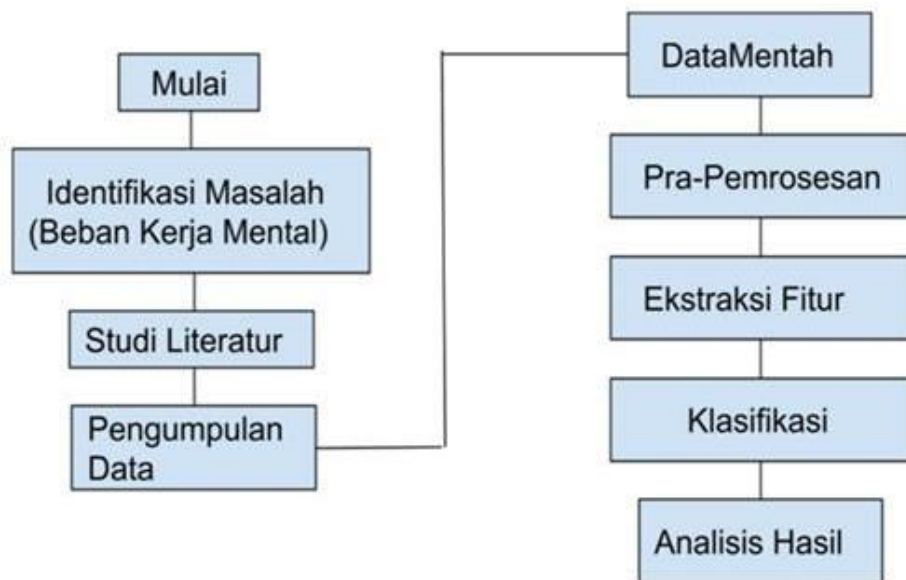
Manfaat dari penelitian ini diantaranya Sinyal EEG dapat digunakan sebagai alat objektif untuk mengukur tingkat beban kerja mental yang dialami oleh individu. Dengan analisis sinyal EEG, peneliti dapat mengidentifikasi biomarker yang terkait dengan tingkat beban kerja mental, seperti perubahan dalam pola aktivitas otak atau frekuensi gelombang tertentu. Hal ini memberikan pendekatan yang lebih tepat dan dapat diandalkan dalam mengukur dan memahami tingkat beban kerja mental individu.

- a) Pemahaman respons otak terhadap beban kerja mental Penelitian EEG memungkinkan pemahaman yang lebih baik tentang respons otak terhadap beban kerja mental yang berlebihan. Dengan mempelajari perubahan pola aktivitas otak, peneliti dapat mengidentifikasi bagaimana otak beradaptasi dan memproses informasi saat menghadapi beban kerja mental yang tinggi. Informasi ini dapat membantu dalam mengembangkan strategi pengelolaan beban kerja yang lebih efektif dan mengoptimalkan kinerja kognitif.
- b) Identifikasi tanda-tanda kelelahan mental Sinyal EEG dapat digunakan untuk mengidentifikasi tanda-tanda kelelahan mental yang terkait dengan beban kerja mental yang berlebihan. Dengan menggunakan informasi ini, dapat dikembangkan sistem pemantauan real-time yang memungkinkan deteksi dini kelelahan mental pada individu. Hal ini dapat membantu mencegah penurunan kinerja dan mengurangi risiko terjadinya kecelakaan atau kesalahan dalam lingkungan kerja.

BAB IV

METODE PENELITIAN

Tahapan penelitian bisa dilihat pada Gambar 3. Berdasarkan Gambar 3 penelitian dimulai dengan melakukan identifikasi masalah dan studi literatur. Lalu pengambilan data yang diunduh dari website IEEE. Dan perhitungan data yang terdiri dari tahap pra-pemrosesan, ekstraksi fitur, pengklasifikasian data serta hasil dan pembahasan. Setelah itu dilakukan analisis data sehingga menghasilkan kesimpulan dari proses ini.



Gambar 2. Diagram Alir Penelitian

4.1 Pra-Pemrosesan Data

Pengambilan data pada penelitian ini, diunduh dari STEW : Simultaneous Task EEG Workload Dataset (<https://ieee-dataport.org/open-access/stew-simultaneous-task-eeg-workload-dataset>) yang terdiri dari 48 subjek. Rekaman sinyal EEG terdiri dari beberapa kanal yaitu AF3-F4, AF3-F4,F7-F8,FC5- FC6,O1-O2,P7-P8,T7-T8. Kanal sinyal EEG yang berada pada daerah frontal AF3 merupakan kanal yang digunakan pada penelitian ini. AF3 dipilih karena merupakan kanal yang

memiliki persentase akurasi paling tinggi untuk klasifikasi cognitive workload atau yang biasa dikenal *mental workload*[18].

Setiap subjek memiliki dua data dalam kondisi santai dan saat melakukan tes. Dalam 1 kanal sinyal EEG terdapat 19200 data numerik. Data yang dimiliki tiap subjek berjumlah 19200 data numerik dan satu data berupa label. Data kemudian digabung antara data saat santai dan saat melakukan tes dengan subjek-subjek lain, sehingga diperoleh data sebanyak 90 data dan 19201 atribut. Setelah data baru berupa data penggabungan seluruh subjek, maka dilakukan pembagian data dengan membagi jumlah kolom dengan 300 yang berguna untuk mendapatkan akurasi sinyal yang lebih detail. Dengan membagi jumlah kolom dengan 300 sehingga didapatkan 64 chunk dimana matriks data setiap chunk adalah 90 300. Penggabungan 64 chunk memperoleh hasil matriks data berjumlah 5760 300 serta satu data berupa label[19].

4.2 Ekstraksi Fitur

Setelah melalui tahap pemrosesan, selanjutnya data melalui proses ekstraksi fitur dengan filter menggunakan aplikasi Waikato Environment for Knowledge Analysis (WEKA). WEKA dikembangkan oleh University of Waikato di Selandia Baru. WEKA mencakup kumpulan algoritma dan visualisasi untuk analisis data dan pemodelan prediktif. WEKA menerapkan semua teknik pembelajaran untuk klasifikasi dan regresi, yaitu pohon keputusan, Support Vector Machines (SVM), logistik dan linier, multi layers perceptrons dan metode nearest neighbour [17].

Attribute Selection yang digunakan pada ekstraksi fitur dikarenakan algoritma ini sangat fleksibel dan memungkinkan berbagai metode pencarian. *Supervised Attribute class order* mengubah urutan kelas sehingga nilai kelas tidak lagi dalam urutan yang ditentukan di header. Nilai akan berada dalam urutan yang ditentukan oleh pengguna, bisa dalam urutan naik/turun berdasarkan frekuensi kelas atau dalam urutan acak. *Supervised Class conditional probability* dapat mengubah nilai atribut nominal atau numerik menjadi probabilitas. *Supervised Nominal to binary* mengubah semua atribut nominal menjadi atribut numerik biner. Atribut nilai K diubah menjadi K untuk atribut biner kelas nominal, atribut biner dibiarkan biner jika opsi '-A' tidak diberikan. Jika kelasnya numerik, K - 1 atribut biner baru dihasilkan dengan cara yang dijelaskan dalam "Classification and Regression Trees" oleh Breiman et al. Dengan memperhitungkan nilai kelas rata-rata yang terkait dengan setiap

nilai atribut. *Attribute Add Cluster* adalah filter yang menambahkan atribut nominal baru mewakili cluster yang ditetapkan ke setiap instance oleh algoritma pengelompokan yang ditentukan dengan kumpulan data pertama atau yang ditentukan.

4.3 Proses Klasifikasi

Setelah selesai pada tahap ekstraksi fitur, selanjutnya dilakukan proses klasifikasi pada data. Dimana pada proses penelitian menggunakan algoritma Random Forest. Algoritma Random Forest mengambil atribut serta data secara acak sesuai ketentuan yang berlaku dalam pembangunan pohon keputusan. Tipe-tipe simpul dijelaskan sebagai berikut[20] :

- A) Simpul Akar : Simpul akar tidak memiliki input serta mempunyai nol atau lebih output.
- B) Simpul Internal : Setiap simpul internal mempunyai tepat satu input serta mempunyai minimal dua output.
- C) Simpul Daun (Simpul Terminal) : Setiap Simpul daun mempunyai tepat satu input serta tidak memiliki output. Simpul daun menyatakan table kelas. Perhitungan nilai entropy untuk data latih menggunakan persamaan (1), berguna dalam menentukan node sebagai pemecah data latih berikutnya (Eko Prasetyo, 2014).

$$E(y) = - \sum_{i=1}^n p(w|y) \log_2 p(w|y) \quad (1)$$

Dimana ($w | y$) adalah semua data latih yang diproses di node, sedangkan untuk memilih fitur yang digunakan sebagai pemecah node menggunakan persamaan Gain (2)(Eko Prasetyo, 2014)

$$G(y) = E(y) - \sum_{i=1}^n p(v|y) \times E(v) \quad (2)$$

Dimana ($w | y$) adalah seluruh nilai pada kelas simpul, $E(v)$ adalah entropi komposisi dari nilai v , dan n adalah banyak berlainan dalam simpul.


BAB V

HASIL DAN LUARAN YANG DICAPAI


Dalam penelitian ini telah dihasilkan tingkat akurasi, *recall*, *precision* dan *F-measure*. dengan beberapa filter. Algoritma random forest yang telah diuji coba pada aplikasi weka dengan filter Attribute Selection, Attribute Class Order, Attribute Class Conditional Probability, dan Nominal Binary. Selanjutnya, dalam penelitian ini telah menghasilkan tingkat akurasi, *recall*, *precision* dan *F-measure*, yang diperoleh dari ekstraksi fitur Wavelet Transform dengan Algoritma Random Forest.

5.1 Data Set

Data set yang diunduh dari STEW: Simultaneous Task EEG Workload Dataset (<https://iee-dataport.org/open-access/stew-simultaneous-task-eegworkload-dataset>) yang terdiri dari 45 subjek laki-laki. Subjek diminta untuk melakukan modul uji kapasitas simultan (SIMKAP) dari Sistem Uji Vienna. STEW Dataset dipilih karena dataset ini menyajikan secara rinci data pada setiap kanal serta untuk menganalisis data jika diklasifikasikan menggunakan beberapa algoritma klasifikasi. Data EEG berupa sinyal mentah atau raw sinyal dengan frekuensi sampling 128 Hz dan terdiri dari 14 kanal. Kanal tersebut adalah AF3, F7, F3, FC5, T7, P7, O1, O2, P8, T8, FC6, F4, F8, AF4. Dalam penelitian ini, label kelas untuk menyatakan mental workload rendah sebagai K1 pada **Gambar 3**, dan untuk menyatakan mental workload tinggi pada **Gambar 4**.




Gambar 3. Plot Sinyal EEG Mental Workload Rendah



Gambar 4. Plot Sinyal EEG Mental Workload Tinggi

5.2 Akurasi Hasil Klasifikasi

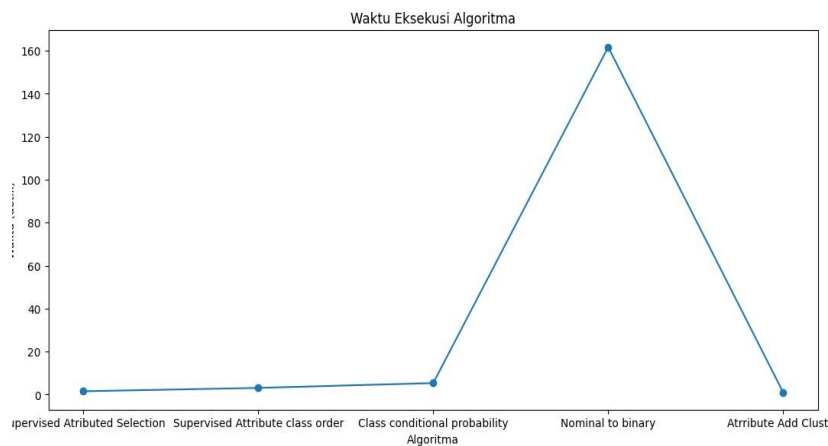
Pada proses klasifikasi, menggunakan algoritma Random Forest sebagai tahap klasifikasi yang digunakan dengan enam filter yang memiliki tingkat akurasi yang berbeda. Tidak dapat dipungkiri bahwa klasifikasi data tidak bisa bekerja secara 100% benar. Oleh karena itu, penelitian ini menggunakan data test dan data uji dengan pembanding 80% dan 20% untuk mencapai tingkat akurasi yang tepat. Data pada penelitian ini terdapat terdapat 3 kelas yaitu K1,K2,K3. Setelah itu dilakukan penghapusan kelas K2 secara manual karena data yang dibutuhkan terdapat pada kelas K1 (Tinggi) dan K3 (Rendah). Distribusi jumlah data kelas tinggi dan rendah bisa dilihat pada gambar **Gambar 5**.



Gambar 5. Scatter Plot Data Class Tinggi dan Rendah


Berdasarkan Tabel 1, hasil akurasi klasifikasi menggunakan algoritma Random Forest yang didapatkan dari WEKA dengan filter *Supervised Attribute Selection* menghasilkan tingkat akurasi 65.20% terendah dengan Recall 0.644, Precision 0.644, dan F-Measure 0.645. Dengan filter *Nominal To Binary* menghasilkan tingkat akurasi 80.87% yang sesuai dengan data uji dan data test yang

dibutuhkan dengan Recall 0.809, Precision 0.807, dan F-Measure 0.807. Dengan filter *Attribute Add Cluster* menggunakan menghasilkan tingkat akurasi lebih tinggi yakni 99% dengan Recall 0.992, Precision 0.992, dan F-Measure 0.992. Dan melakukan uji coba tanpa filter yang menggunakan algoritma Random Forest menghasilkan akurasi 66.25% dengan Recall 0.663, Precision 0.655, dan F-Measure 0.654. Dapat disimpulkan bahwa performa WEKA dalam proses klasifikasi didapatkan dari segi hasil nilai. Distribusi jumlah data kelas tinggi dan rendah untuk workload tinggi dan rendah bisa dilihat pada **Gambar 6**.



Gambar 6. Waktu eksekusi algoritma

Running time untuk train dan test bisa dilihat secara berurutan di gambar 6 dan 7. Gambar 6 menunjukkan bahwa menggunakan filter *Nominal to Binary* algoritma Random Forest memerlukan waktu lebih lama untuk mendapatkan data uji yang sesuai. Tetapi, menggunakan filter *Nominal to Binary* pada algoritma pada WEKA membutuhkan ruang penyimpanan lebih banyak karena hasil akurasi yang lebih tinggi. Demikian juga untuk test yang tampak di **Gambar 7**.



Gambar 7. Waktu Data Uji

Berdasarkan **Gambar 8** hasil klasifikasi menggunakan Wavelet Transform dan Algoritma Random Forest menggunakan bahasa pemrograman python didapatkan tingkat akurasi pada proses pengujian adalah 98.33%.

Akurasi yang dihasilkan pada proses pengujian adalah 98.33%

Dan berikut merupakan hasil evaluasi secara keseluruhan:

	precision	recall	f1-score	support
0	0.92	1.00	0.96	12
1	1.00	1.00	1.00	13
2	1.00	1.00	1.00	17
3	1.00	0.94	0.97	18
accuracy			0.98	60
macro avg	0.98	0.99	0.98	60
weighted avg	0.98	0.98	0.98	60

Gambar 8.

5.3 Pembahasan

Penggunaan Filter *Supervised Attribute Selection* menunjukkan tingkat akurasi yang rendah dan konsistensi yang tidak terlalu baik, karena tingkat akurasi dan nilai Recall, Precision, dan F-Measure yang serupa. *Nominal To Binary* yang digunakan untuk mengubah atribut nominal menjadi atribut biner agar dapat digunakan dalam algoritma Random Forest, penggunaan filter ini meningkatkan tingkat akurasi secara signifikan dibandingkan dengan penggunaan filter sebelumnya. Hal ini menunjukkan bahwa transformasi atribut nominal menjadi biner membantu dalam meningkatkan performa model. *Filter Attribute Add Cluster* menambahkan atribut berdasarkan pembagian data ke dalam cluster-cluster yang dibentuk. Hasil ini menunjukkan tingkat akurasi yang sangat tinggi dan konsistensi yang baik dalam prediksi klasifikasi. Penyebab performa yang sangat tinggi adalah adanya penambahan atribut yang relevan dan menggambarkan pola-pola dalam data dengan lebih baik.

Dalam keseluruhan analisis, penggunaan filter *Nominal To Binary* dan *Attribute Add Cluster* menghasilkan performa yang lebih baik dibandingkan dengan filter *Supervised Attribute Selection*. Filter *Nominal To Binary* membantu dalam mengatasi masalah atribut nominal, sementara filter *Attribute Add Cluster* menambahkan atribut yang relevan.

BAB VII

KESIMPULAN DAN SARAN

Berdasarkan analisis yang dilakukan, dapat diambil kesimpulan bahwa penggunaan filter *Supervised Attribute Selection* menunjukkan tingkat akurasi yang rendah sedangkan filter *Nominal To Binary* membantu dalam meningkatkan tingkat akurasi secara signifikan dibandingkan dengan penggunaan filter sebelumnya, terutama dalam mengatasi masalah atribut nominal. Dan untuk filter *Attribute Add Cluster* memberikan peningkatan performa yang baik dalam prediksi klasifikasi dengan tingkat akurasi yang tinggi dan konsistensi yang baik. Secara keseluruhan, penggunaan filter *Nominal To Binary* dan *Attribute Add Cluster* menghasilkan performa yang lebih baik dibandingkan dengan filter *Supervised Attribute Selection*.

Berdasarkan analisis yang dilakukan menggunakan Bahasa Pemrograman *Python* yang dilakukan, dapat disimpulkan bahwa penggunaan *Transformasi Wavelet* untuk menganalisis sinyal bergerak guna mendapatkan informasi spektrum frekuensi dan waktunya secara bersamaan dengan menggunakan Algoritma Random Forest menghasilkan akurasi Tinggi yaitu sebesar 98.33%. Dengan demikian, transformasi atribut nominal menjadi biner dan penambahan atribut berdasarkan cluster terbukti berkontribusi dalam meningkatkan performa model dan menghasilkan prediksi yang lebih akurat. Selain itu penggunaan Transformasi Wavelet menggunakan algoritma *Random Forest* berhasil menghasilkan prediksi yang akurat. Menunjukkan bahwa transformasi *attribute nominal* menjadi biner dan penambahan atribut berdasarkan cluster dapat berkontribusi signifikan dalam meningkatkan performa model dan menghasilkan prediksi yang lebih akurat dibandingkan dengan model yang tidak menggunakan filter.

BAB VIII

DAFTAR PUSTAKA

- [1] I. A. Ridlo, D. Administrasi, K. Kesehatan, K. Masyarakat, dan U. Airlangga, “Pandemi COVID-19 dan Tantangan Kebijakan Kesehatan Mental di Indonesia”, doi: 10.20473/jpkm.v5i12020.155-164.
- [2] A. Korespondensi, N. Ulfah, J. Kesehatan, M. Fkik, P. J. Nurcahyo, dan I. Dwiandhono, “Artikel Penelitian 477 Model Kuantitatif Manajemen Kelelahan dan Beban Kerja untuk Peningkatan Produktivitas Pekerja Penggilingan Padi Quantitative Models of Fatigue and Workload Management for Improving Productivity of Rice Milling Labors.”
- [3] F. N. Rahman dan A. Y. Pratama, “Analisis Beban Kerja Mental Pekerja Train Distribution PT. Solusi Bangun Indonesia,” 2022.
- [4] D. Kusumaningrum, J. Matematika, F. Matematika, D. Ilmu, P. Alam, dan E. M. Imah, “STUDI KOMPARASI ALGORITMA KLASIFIKASI MENTAL WORKLOAD BERDASARKAN SINYAL EEG,” 2020.
- [5] Y. Zhou, S. Huang, Z. Xu, P. Wang, X. Wu, dan D. Zhang, “Cognitive Workload Recognition Using EEG Signals and Machine Learning: A Review,” *IEEE Trans Cogn Dev Syst*, vol. 14, no. 3, hlm. 799–818, Jun 2022, doi: 10.1109/tcds.2021.3090217.
- [6] K. Guan, Z. Zhang, X. Chai, Z. Tian, T. Liu, dan H. Niu, “EEG Based Dynamic Functional Connectivity Analysis in Mental Workload Tasks With Different Types of Information,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 30, hlm. 632–642, 2022, doi: 10.1109/tnsre.2022.3156546.
- [7] L. Longo, “Modeling Cognitive Load as a Self-Supervised Brain Rate with Electroencephalography and Deep Learning,” *Brain Sci*, vol. 12, no. 10, hlm. 1416, Okt 2022, doi: 10.3390/brainsci12101416.
- [8] A. Gupta, G. Siddhad, V. Pandey, P. P. Roy, dan B.-G. Kim, “Subject-Specific Cognitive Workload Classification Using EEG-Based Functional Connectivity and Deep Learning,” *Sensors*, vol. 21, no. 20, hlm. 6710, Okt 2021, doi: 10.3390/s21206710.
- [9] Z. Pei, H. Wang, A. Bezerianos, dan J. Li, “EEG-Based Multiclass Workload Identification Using Feature Fusion and Selection,” *IEEE Trans Instrum Meas*, vol. 70, hlm. 1–8, 2021, doi: 10.1109/tim.2020.3019849.

- [10] Z. Markov dan I. Russell, "An introduction to the WEKA data mining system," dalam *Annual Conference on Innovation and Technology in Computer Science Education*, 2006. [Daring]. Tersedia pada: <https://api.semanticscholar.org/CorpusID:1185943>
- [11] R. Anggara dan Y. Rahayu, "Sistem Electroencephalogram (EEG) Untuk Analisis Sinyal Gelombang Otak Pada Pasien Depresi."
- [12] I. Herdiansyah *dkk.*, "Klasifikasi Sinyal EEG Terhadap Tiga Kondisi Pikiran Menggunakan Autoregressive dan Adaptive Backpropagation," 2017.
- [13] R. Baydemir, F. Latifoğlu, dan F. Orhanbulucu, "Classification Mental Workload Levels from EEG Signals with 1D Convolutional Neural Network," *The European Journal of Research and Development*, vol. 2, no. 4, hlm. 13–23, Des 2022, doi: 10.56038/ejrnd.v2i4.193.
- [14] N. Farnaaz dan M. A. Jabbar, "Random Forest Modeling for Network Intrusion Detection System," dalam *Procedia Computer Science*, Elsevier B.V., 2016, hlm. 213–217. doi: 10.1016/j.procs.2016.06.047.
- [15] M. Schonlau dan R. Y. Zou, "The random forest algorithm for statistical learning," *The Stata Journal: Promoting communications on statistics and Stata*, vol. 20, no. 1, hlm. 3–29, Jun 2020, doi: 10.1177/1536867x20909688.
- [16] Togu Novriansyah Turnip, Chatrine Febryanti Manurung, Yogi Septian Lubis, dan Rachel Gultom, "Klasifikasi Malware Android Aplikasi Menggunakan Random Forest Berdasarkan Fitur Statik," *Teknik Informatika dan Sistem Informasi*, vol. 10, hlm. 926–936, Mar 2023.
- [17] A. Wahab, S. Samarinda, I. Lishania, R. Goejantoro, dan Y. N. Nasution, "Perbandingan Klasifikasi Metode Naive Bayes dan Metode Decision Tree Algoritma (J48) pada Pasien Penderita Penyakit Stroke di RSUD Comparison of the Classification for Naive Bayes Method and the Decision Tree Algorithm (J48) for Stroke Patients in Abdul Wahab Sjahranie Samarinda Hospital," *Jurnal EKSPONENSIAL*, vol. 10, no. 2, 2019.
- [18] W. L. Lim, O. Sourina, dan L. P. Wang, "STEW: Simultaneous task EEG workload data set," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 26, no. 11, hlm. 2106–2114, Nov 2018, doi: 10.1109/TNSRE.2018.2872924.
- [19] R. L. Charles dan J. Nixon, "Measuring mental workload using physiological measures: A systematic review," *Appl Ergon*, vol. 74, hlm. 221–232, Jan 2019, doi: 10.1016/J.APERGO.2018.08.028.
- [20] Pang-Ning Tan, Michael Steinbach, Arnuj Karpatne, dan Vipin Kumar, *Intruduction to Data Mining*, 2nd Edition. Pearson, 2018.

LOGBOOK

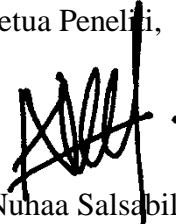
No	Tanggal	Kegiatan
1	20 Mei 2023	<p>Catatan:</p> <ul style="list-style-type: none"> a. Identifikasi masalah terkait dengan beban kerja mental pengaruh dengan sinyal EEG b. Evakuasi relevansi dan urgensi terkait penelitian ini <p>Dokumen Pendukung: ✓ <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/></p>
2	15 Juni 2023	<p>Catatan:</p> <ul style="list-style-type: none"> a. Melakukan studi literatur terkait deteksi beban mental menggunakan kecerdasan buatan b. Memahami dan mempelajari metode yang telah digunakan dalam penelitian serupa <p>Dokumen Pendukung: ✓ <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/></p>
3	21 Juli 2023	<p>Catatan:</p> <ul style="list-style-type: none"> a. Memahami data terhadap sumber data yang digunakan <p>Dokumen Pendukung: ✓ <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/></p>
4	2 Agustus 2023	<p>Catatan:</p> <ul style="list-style-type: none"> a. Menyesuaikan agar sesuai dengan keperluan analisis b. Melakukan kebenaran data terkait data yang didapatkan <p>Dokumen Pendukung: ✓ <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/></p>
5	20 September 2023	<p>Catatan:</p> <ul style="list-style-type: none"> a. Melakukan pra-pemrosesan data dengan membagi data latih dan data uji

		Dokumen Pendukung: <input checked="" type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/>
6	3 Oktober 2023	Catatan: <ol style="list-style-type: none"> Menentukan fitur-fitur yang relevan Menggunakan teknik ekstraksi fitur yang sesuai dengan konteks penelitian Melakukan optimalisasi terhadap fitur-fitur untuk meningkatkan performa model Dokumen Pendukung: <input checked="" type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/>
7	25 November 2023	Catatan: <ol style="list-style-type: none"> Memilih algoritma klasifikasi yang tepat untuk memproses data Melatih model menggunakan data latih Menyesuaikan dan mengoptimalkan model untuk meningkatkan akurasi klasifikasi Dokumen Pendukung: <input checked="" type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/>
8	30 November 2023	Catatan: <ol style="list-style-type: none"> Menganalisis output dari model klasifikasi Mengevaluasi keefektifan model dalam mendeteksi beban kerja mental Pendukung: <input checked="" type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/> <input type="checkbox"/>

Surabaya,

28 November 2023

Ketua Peneliti,



(Nuhaa Salsabila Shidqiyyah) NIM
22031554045

